Agente de consultas en lenguaje natural sobre la EPH

Oct 23, 2026 · @Damian

Este documento presenta un agente que responde preguntas en lenguaje natural sobre los microdatos de la Encuesta Permanente de Hogares (EPH) del INDEC: arma el SQL, lo ejecuta sobre una base de datos relacional y devuelve la respuesta con el SQL y los supuestos que usó. El alcance inicial es un único trimestre, el primero de 2026 (1T 2026), que es el último publicado al momento de implementar esto; sumar otros trimestres y la integración con Claude por MCP quedan como mejoras futuras.

Cumple tres funciones: compartir la propuesta, guiar el desarrollo (el plan de trabajo del final se va tildando) y documentar cómo funciona el producto terminado. Se actualiza a medida que avanza el proyecto; el detalle de cada decisión queda en la bitácora del repositorio.

Objetivo

Un agente desplegado en la nube que responda con precisión preguntas sobre mercado laboral e ingresos, por ejemplo *"¿cuál fue la tasa de desocupación de las mujeres en Gran Córdoba en el 1T 2026?"*.

Cada respuesta incluye:

- el valor o la tabla resultante,
- el SQL ejecutado, para que sea auditable,
- los supuestos tomados (qué variable de ingreso, qué período),
- advertencias cuando la muestra es chica y la estimación es poco confiable.

El criterio de éxito es medible: un porcentaje de acierto sobre un golden set de preguntas con respuesta conocida, validadas contra los informes oficiales del INDEC cuando existen.

Datos

Usamos la **EPH continua**: trimestral, 31 aglomerados urbanos, microdatos publicados desde el 2T 2016 en dos tablas (individuos y hogares). El alcance inicial usa un único trimestre, el primero de 2026 (1T 2026), que es el último publicado al momento de

implementar esto.

Base	Cobertura	Frecuencia	Uso
EPH continua	31 aglomerados urbanos	Trimestral	**Elegida**: comparación entre aglomerados; series trimestrales en una mejora futura
EPH total urbano	Aglomerados + localidades de 2.000 habitantes o más	Anual (3er trimestre)	Descartada por ahora; candidata a una segunda fuente

Los microdatos se descargan de la página de bases de datos del INDEC y se cargan en una **base de datos relacional**. Las tablas de individuos y hogares quedan tal como las publica el INDEC, y sobre ellas se construye la capa semántica.

Capa semántica

Las tablas del INDEC usan nombres de columnas y valores codificados: por ejemplo, el sexo está en `CH04`, con 1 = varón y 2 = mujer. Sin contexto, un modelo no puede interpretarlos. Por eso, sobre las tablas se crean **vistas** con nombres y valores legibles, acompañadas de **metadatos** que describen cada columna; el agente trabaja solo con esa capa.

Esos metadatos forman el diccionario de datos: para cada columna, qué significa, qué valores toma, a quién aplica y con qué ponderador se estima. El agente lo consulta para decidir qué columnas usar y cómo. El diccionario se arma con el Diseño de registros y estructura para las bases preliminares Hogar y Personas del 1T 2026 (publicado en agosto de 2026).

Tres niveles

1. **Vistas legibles** (`personas`, `hogares`) sobre las tablas crudas, que quedan intactas. Nombres claros (`sexo = 'Mujer'`), valores especiales convertidos en `NULL`, universo aplicado en los datos (el ingreso laboral es `NULL` fuera de los ocupados) y columnas derivadas (`es_desocupado`, `grupo_edad`). Esto hace imposibles varios errores, incluso en SQL libre.

2. **Metadatos de columnas** guardados en la base, armados a partir del diseño de registro del INDEC y versionados junto con el resto del proyecto.
3. **Métricas curadas y parametrizables** (`tasa_desocupacion(filtros, agrupar_por)`), solo donde la evaluación muestre fallos recurrentes.

Ficha de cada columna

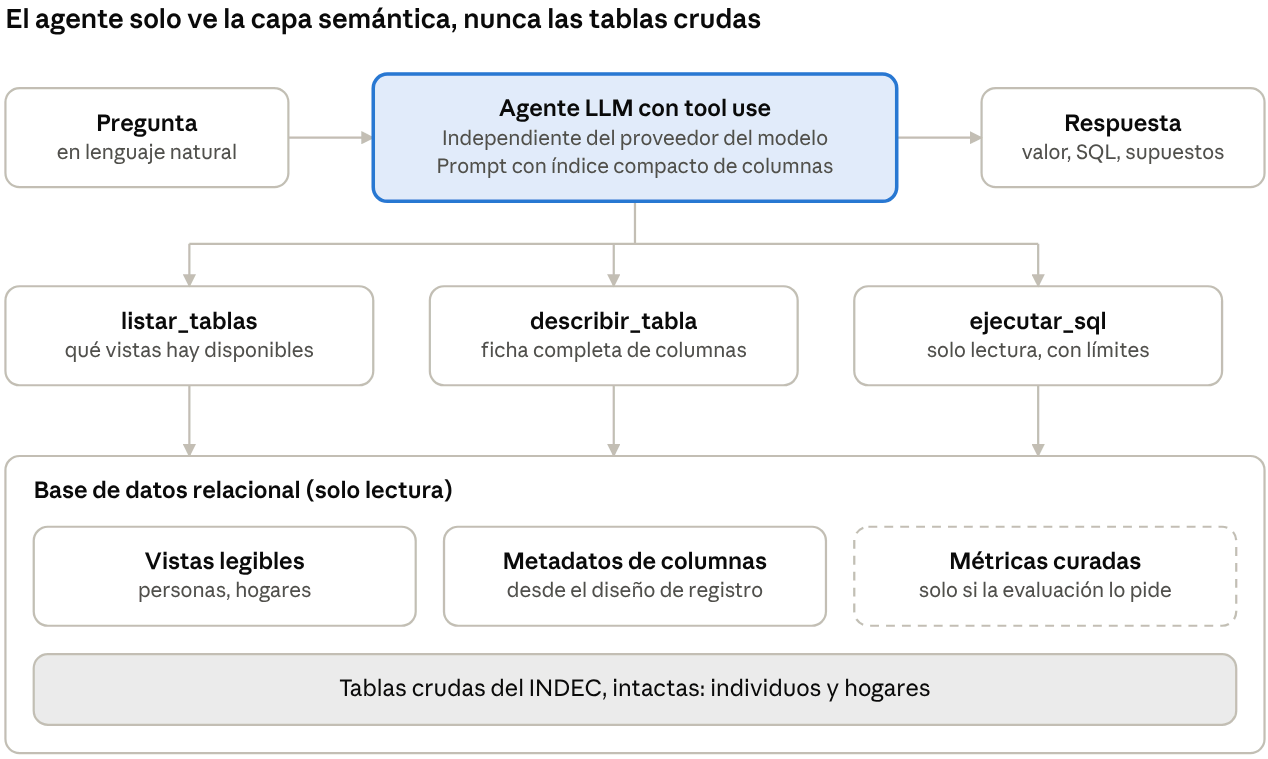
La ficha describe solo las columnas de las vistas, que es lo único que ve el modelo. Los códigos originales del INDEC se usan para construir las vistas y no llegan al modelo.

Campo	Para qué sirve
Nombre y vista	En qué vista está la columna y si hace falta unir personas con hogares
Descripción	Qué mide, en lenguaje claro
Tipo	Categórica, numérica o identificador: define qué agregaciones tienen sentido
Valores posibles	Las etiquetas que puede tomar (por ejemplo, “Mujer” o “Desocupado”), para filtrar sin inventar valores
Significado de NULL	Si un NULL en esa columna indica que no respondió o que no le corresponde, para interpretarlo o contar esos casos
Universo	A quién aplica la columna; fuera de ese universo la vista deja NULL
Ponderador	Qué columna de ponderación usar para esa medida
Sinónimos	“desempleo”, “sueldo”: ayudan a encontrar la columna
Notas	Advertencias metodológicas; al sumar trimestres, desde y hasta cuándo existe la columna

Los clasificadores largos (CNO, CAES) van en tablas aparte. La parte estadística (valores distintos, rangos, nulos) se genera con un profiling automático que además valida el diccionario.

Arquitectura

Un único agente con tool use, sin framework de orquestación: un loop simple (pregunta → herramientas → resultados → respuesta), con un número acotado de reintentos cuando la consulta falla.



arquitectura del agente · 3 herramientas sobre la capa semántica

El agente solo accede a la base a través de tres herramientas y solo ve las vistas; las tablas crudas quedan debajo, sin cambios. La caja punteada se agrega solo si la evaluación la justifica.

Herramienta	Qué hace
`listar_tablas()`	Lista las vistas disponibles con su descripción
`describir_tabla(nombre)`	Devuelve la ficha completa de cada columna: códigos, valores especiales, universo, ponderador
`ejecutar_sql(query)`	Ejecuta la consulta y devuelve el resultado o el error, para que el modelo corrija

Ejecución segura: acceso de solo lectura a la base, validación previa de que la consulta sea un único `SELECT`, límite de filas y timeout.

Salida: el agente devuelve el valor, el SQL, los supuestos y una respuesta en texto que explicita esos supuestos y advierte cuando la muestra es chica.

Estrategia de modelos

El modelo final todavía no está definido; se elegirá comparando candidatos con el golden set. Para controlar costos, el desarrollo usa tres perfiles intercambiables por configuración:

Perfil	Modelo	Para qué
`local`	Modelo gratuito que corre en la máquina de desarrollo	Probar el loop, las herramientas y la ejecución de consultas; trabajar sin conexión
`dev`	Free tier de un proveedor en la nube	Iterar sobre la calidad
`eval`	Uno o dos candidatos pagos	Mediciones formales y elección del modelo final

- **Independencia del proveedor:** cambiar de modelo es un cambio de configuración, no de código.
- **Riesgo:** un modelo chico falla más y puede llevar a sobrediseñar para compensar limitaciones que el modelo final no tiene. Por eso la calidad se mide con `dev` y `eval`, no con `local`.

Evaluación

La evaluación central es **por ejecución**: se compara el valor que devuelve el agente con el esperado, con tolerancia. Es determinística, gratuita y reproducible, que es lo que necesita un test de regresión.

Qué se evalúa	Método
¿El número es correcto?	Comparación del resultado con el esperado, con tolerancia

Qué se evalúa	Método
¿Usó bien los datos (ponderador, vista, universo)?	Reglas sobre el SQL generado
¿Incluye el SQL, los supuestos y las advertencias que corresponden?	Reglas simples sobre la salida estructurada

Golden set

Cada caso tiene pregunta, SQL esperado, valor esperado, fuente, tolerancia, categoría y dificultad:

```
- id: lab_001
  pregunta: "¿Cuál fue la tasa de desocupación en Gran Córdoba en el 1T
2026?"
  sql_esperado: "SELECT ..."
  valor_esperado: 0.083
  fuente: "Informe técnico INDEC, mercado de trabajo 1T 2026"
  tolerancia: 0.001
  categoria: tasas_laborales
  dificultad: baja
```

(Valores ilustrativos.)

- **Validación contra el INDEC:** cuando existe un valor publicado, el golden set lo usa. Así se prueba toda la cadena, incluida la carga de datos.
- **Salida estructurada del agente:** `{valor, sql, supuestos, respuesta}`, para comparar un campo y no parsear texto.
- **Normalización al comparar:** porcentaje o fracción, nombres de columnas, orden de filas.
- **Cobertura diseñada desde el inicio:** tasas, ingresos, cruces, ambigüedades y trampas (preguntas por períodos que no están en la base, preguntas donde `COUNT(*)` sin ponderar da un número plausible, o sin respuesta posible, como un aglomerado que no existe).
- **Conjunto de reserva** que no se mira al iterar, para detectar sobreajuste de prompts y descripciones.

Regresiones

- Cada pregunta se corre varias veces (por ejemplo 3) y se mide la tasa de acierto por pregunta: los modelos no son del todo determinísticos, ni con temperatura 0.
- Cada corrida se guarda con el commit, el perfil, el modelo, el resultado y el SQL. Una regresión es una pregunta que pasaba y ahora falla de forma consistente (3/3 a 0/3); una baja leve (3/3 a 2/3) puede ser ruido o un caso frágil para revisar.

Ciclo de desarrollo

El desarrollo está guiado por evaluaciones: se arranca con una línea base mínima (vistas con descripciones y SQL libre) y cada componente nuevo, como una métrica o una validación, se agrega solo cuando un fallo medido lo justifica. Durante el desarrollo no se despliega nada: el agente, la base y la evaluación corren en local, y solo el modelo está en la nube.

Versionado

Todo lo que define el comportamiento del agente (descripciones, vistas, prompts y golden set) va versionado, para que cada corrida de evaluación quede asociada a una versión. La base se reconstruye siempre con el mismo proceso, y las descripciones no se editan a mano en ella.

Iteración

1. Correr la evaluación y analizar los fallos.
2. Clasificar cada fallo (variable equivocada, ponderador, universo, ambigüedad) y formular una hipótesis.
3. Hacer **un solo** cambio: descripción, vista, métrica o prompt.
4. Probar a mano la pregunta que fallaba, con el perfil `dev`.
5. Correr el golden set completo y comparar con la corrida anterior: ¿se corrigió? ¿hubo regresiones?
6. Si mejora, commit y entrada en la bitácora; si no, revertir.
7. Agregar preguntas nuevas que cubran el tipo de fallo encontrado.
8. Cada tanto, una corrida con el perfil `eval` y contra el conjunto de reserva.

Bitácora de decisiones

Cada cambio queda registrado como fallo, hipótesis, cambio y efecto medido. Por ejemplo: *"lab_007 y lab_012 promediaban ingreso sobre toda la población → la vista pone NULL fuera del universo → 2 preguntas corregidas, 0 regresiones"*. Sirve para entender por qué existe cada pieza y para revisar qué sobra al cambiar de modelo.

Despliegue

Si el desarrollo sigue el ciclo anterior, desplegar es empaquetar lo que ya existe, sin rediseño:

- **Contenedor** con el agente y la base, generada con el mismo proceso que en desarrollo y en modo solo lectura.
- **Configuración de producción** con el modelo elegido en la etapa de evaluación; las credenciales como secretos.
- **Evaluación automática:** cada cambio corre el golden set antes de desplegarse; si hay regresiones, no se despliega.
- **Actualización de datos:** fuera del alcance inicial; se define junto con la incorporación de nuevos trimestres (ver Mejoras futuras).

La plataforma (Cloud Run, un VPS u otra) queda abierta: con un contenedor y una base de solo lectura, cualquier opción sirve y no condiciona el desarrollo.

Riesgos

Riesgo	Mitigación
Números plausibles y equivocados (ponderador, universo)	Vistas que fuerzan NULLs y universo; reglas sobre el SQL; evaluación por ejecución
Ambigüedad en las preguntas	Supuestos explícitos en la respuesta o pregunta de aclaración; métricas curadas para lo frecuente
Estimaciones con muestra chica	Advertencia en la respuesta según el tamaño de muestra
Sobreajuste al golden set	Conjunto de reserva; cobertura diseñada desde el inicio

Riesgo	Mitigación
Muletas para el modelo de desarrollo	Bitácora de decisiones; revisión al cambiar de modelo
Cambios en el diseño de registro del INDEC	Alcance inicial de un solo trimestre; al sumar trimestres, análisis de cambios antes de cada carga

Plan de trabajo

Las fases siguen el ciclo de desarrollo: primero una línea base mínima y medida, después iteración guiada por la evaluación. Las tareas de la fase 4 no están definidas de antemano: salen de los fallos que muestre la evaluación.

Fase 0: datos

- [ ] Cargar la EPH continua del 1T 2026
- [ ] Validar las tasas del 1T 2026 contra el informe técnico del INDEC
- [ ] Crear el repositorio y un proceso reproducible para construir la base

Fase 1: capa semántica inicial

- [ ] Vistas `personas` y `hogares` para las variables de mercado laboral e ingresos
- [ ] Valores especiales a `NULL`, universo aplicado y columnas derivadas
- [ ] Metadatos de ese grupo de variables, a partir del diseño de registro
- [ ] Script de profiling para validar el diccionario contra los datos

Fase 2: agente base

- [ ] Loop con las tres herramientas y ejecución segura
- [ ] Índice compacto de columnas generado desde los metadatos
- [ ] Salida estructurada `{valor, sql, supuestos, respuesta}`
- [ ] Perfiles `local` y `dev`

Fase 3: evaluación

- [ ] Golden set inicial con cobertura por categoría, incluidas las trampas

- [ ] Conjunto de reserva
- [ ] Ejecución automática del golden set con repeticiones y registro de corridas
- [ ] Primera medición: la línea base

Fase 4: iteración

- [ ] Ciclo de mejora con bitácora de decisiones, hasta alcanzar el nivel de acierto buscado
- [ ] Ampliar el golden set con cada tipo de fallo encontrado

Fase 5: elección del modelo

- [ ] Correr el golden set y la reserva con el perfil `eval` sobre los candidatos
- [ ] Elegir el modelo final y revisar qué muletas sobran

Fase 6: despliegue

- [ ] Contenedor con el agente y la base de solo lectura
- [ ] Evaluación en CI como condición para desplegar
- [ ] Dejar explícito en las respuestas el período que cubren los datos (1T 2026)

Mejoras futuras

Incorporar otros trimestres

Sumar trimestres habilita series temporales y comparaciones entre períodos. Cada trimestre se incorpora con un análisis previo de cambios, porque el diseño de registros no siempre es igual entre trimestres.

Para cada trimestre nuevo:

1. Comparar su diseño de registros con el del último trimestre cargado: variables nuevas, eliminadas o con códigos distintos, y notas para usuarios.
2. Cargarlo y comparar con el profiling qué columnas tienen datos y qué valores aparecen; los datos son la fuente de verdad, aunque el documento no avise.
3. Actualizar lo que corresponda: metadatos (con desde y hasta cuándo existe cada variable), vistas y métricas.
4. Agregar al golden set preguntas de ese período y, cuando haya varios, preguntas de series.

5. Correr la evaluación completa para detectar regresiones y registrar el análisis en la bitácora.

Con esto definido, el procedimiento pasa a ser parte del despliegue: cada publicación del INDEC dispara el análisis, la carga y la evaluación antes de publicar una nueva imagen.

Integración con Claude por MCP

Exponer el agente como un servidor MCP (Model Context Protocol) permite usarlo desde la app de Claude: por ejemplo, pedir un gráfico de la desocupación por aglomerado y que Claude obtenga los datos y arme la visualización.

	Exponer el agente completo	Exponer las herramientas
Qué ve Claude	Una herramienta: `consultar_eph(pregunta)`	`listar_tablas`, `describir_tabla`, `ejecutar_sql` y las métricas curadas
Quién arma el SQL	El agente propio, con su modelo	Claude
Ventaja	Se usa exactamente lo evaluado con el golden set	Más simple; Claude accede directo a los datos
Desventaja	Dos modelos en cadena: más costo y latencia	Hay que evaluar a Claude en el rol de agente

- Las herramientas devuelven datos (filas, SQL y supuestos), no imágenes ni texto: la visualización la arma Claude.
- La capa semántica, las herramientas y el golden set se reutilizan en ambas opciones; el golden set sirve también para evaluar a Claude como agente.
- Para uso personal alcanza un servidor MCP local en la app de escritorio; para usarlo desde cualquier dispositivo o compartirlo, hace falta un servidor remoto por HTTPS, que se suma al despliegue.
- Los gráficos de evolución dependen de la mejora anterior: con un solo trimestre no hay series.

Evaluación de la respuesta en texto

El alcance inicial evalúa el valor y los datos que lo acompañan (SQL, supuestos y advertencias). Como mejora, la calidad de la respuesta en texto se puede evaluar con LLM as a Judge: un modelo que revisa si el texto es fiel a los números, si explica los supuestos con claridad y si maneja bien las preguntas ambiguas. Como ahí no hay un valor exacto contra el cual comparar, complementa la evaluación por ejecución sin reemplazarla.

Fuentes

- INDEC – Bases de datos
- INDEC – EPH, Diseño de registros y estructura para las bases preliminares Hogar y Personas, 1T 2026